コスト試算書

- 対象: オンライン診療における不審発言検知システム
- 作成日: 2026-11-08
- 試算通貨: USD
- 対象リージョン: `asia-northeast1`（Cloud Run）
- ステータス: 初版・仮定を含む試算

> **重要:** 本書は、2026-11-08時点で確認できたリポジトリ実装とGoogle公式料金情報に基づく概算である。Cloud Runは対象プロジェクトにサービスがデプロイされていないため、実請求額ではない。実際のトークン使用量、API応答時間、デプロイ後の課金メトリクスで更新する。

1. 目的と対象範囲

本書では、デモ・開発期間における次の費用を試算する。

- Gemini APIによる音声・映像分析
- Cloud Run上のFrontend / Backend稼働
- 将来Speech-to-Textを導入した場合の追加費用
- Firestoreを導入した場合の扱い
- 無料枠・クレジット・コスト削減策

費用はサービスごとに分けて記載する。為替、税、ネットワーク転送料、Artifact Registry、Cloud Build、Secret Manager、ログ保管、その他Google Cloudサービスの費用は、料金・利用量が確定していないため基本合計に含めない。

2. 実装調査結果

2.1 現行のメディア取得・送信

確認したファイル:

- `frontend/src/features/capture/MediaCaptureService.ts`
- `frontend/src/lib/api/detectionClient.ts`
- `frontend/src/stores/detectionStore.ts`
- `frontend/src/app/page.tsx`
- `backend/app/api/v1/routes.py`
- `backend/app/detectors/gemini_detector.py`
- `backend/app/core/config.py`
- `infra/cloudrun/deploy-backend.sh`

確認できた仕様:

項目 確認結果

音声モード `getUserMedia({ audio: true, video: false })`

映像モード `getUserMedia({ audio: true, video: true })`

録画時間 UIから `5000` ms を指定

Blob MediaRecorderでチャンクをまとめて1つのBlobにする

API送信 `POST /api/v1/detect` に `media` と任意の `context` を送信

Geminiへの入力 メディアデータを1つのPartとして渡す

送信回数 `recordAndAnalyze()` 1回につき検知APIを1回呼び出す

連続監視 現行コードでは未実装。MediaCaptureServiceに将来拡張のTODOあり

`kind="video"` の場合はマイク音声とカメラ映像を同時に取得する。音声と映像を別々のAPIリクエストに分けて送る実装ではない。

現行実装の費用と、15分通話を5秒ごとに送る将来構想の費用を混同しない。

2.2 Geminiの接続方式・モデルに関する不一致

リポジトリ内に次の不一致がある。

情報源 記載内容

`backend/app/core/config.py` `gemini-2.5-flash`、`gemini_use_vertexai=False`

`infra/cloudrun/deploy-backend.sh` `DETECTOR_BACKEND=gemini`、`GEMINI_MODEL=gemini-2.5-flash`、Secret Managerから`GEMINI_API_KEY`を注入

`docs/setup-gcp.md` Vertex AI、`gemini-3.5-flash`

`docs/api-contract.md` 応答例に`gemini-2.5-flash`

`docs/adr/0001-initial-tech-stack.md` Gemini APIと記載。ADR状態はProposed

本試算のGemini料金は、**現行のCloud Runデプロイスクリプト とBackend設定に合わせ、Gemini Developer APIの`gemini-2.5-flash`有料標準料金**を採用する。Vertex AIへの切り替えが決まった場合は、接続方式・モデル・料金表を再確認する。

3. 試算シナリオ

3.1 現行実装

UIからの1回の操作で5秒間の音声または音声＋映像を取得し、1回だけGeminiに送信する。

項目 条件

1操作あたりの録画時間 5秒 Geminiリクエスト 1回 試算回数 10回 / 50回 / 100回

ここでいう10回・50回・100回は、15分通話の回数ではなく、5秒間の分析操作回数である。

3.2 将来の連続監視（仮定）

項目 条件

1通話あたりの時間 15分（900秒） Gemini送信間隔 5秒 1通話あたりのリクエスト 900 ÷ 5 = 180回 試算する通話数 10回 / 50回 / 100回

```
通話数    Geminiリクエスト数    分析対象時間
```

```
  10              1,800          150分
  50              9,000          750分
 100             18,000        1,500分
```

これは将来機能の費用上限を把握するための仮定であり、現在のUI・MediaCaptureServiceが実現している動作ではない。

4. Gemini API料金

4.1 公式単価

`gemini-2.5-flash` のGemini Developer API標準有料枠を使用する。

トークン種別 単価

入力（テキスト / 画像 / 動画） $0.30 / 1,000,000 tokens 入力（音声） $1.00 / 1,000,000 tokens 出力（思考トークンを含む） $2.50 / 1,000,000 tokens

無料枠も掲載されているが、無料枠の利用データはサービス改善に使用される場合がある。有料枠ではサービス改善に使用しない旨が料金表に記載されている。機微な音声・映像を扱うため、無料枠を利用する場合はデータ取扱条件を事前に確認する。

4.2 トークン数の仮定

公式トークン資料に基づく概算:

- 音声: 約32 tokens / 秒
- 動画（静的処理・デフォルト）: 約100 tokens / 秒（低解像度）、約300 tokens / 秒（高解像度）。デフォルトは1 FPSのフレームサンプリング。
- 動画の100 / 300 tokens毎秒は、フレームと音声を含む動画入力の概算として扱う。音声を別途加算して二重計上しない。
- 出力: 1リクエストあたり200 tokensと仮定する。実測値ではない。
- プロンプト・contextの入力トークンは未計測のため計算から除外する。

実際の利用量はモデル、MIMEタイプ、解像度、フレームレート、プロンプト、応答内容で変わる。利用開始後はレスポンスのusage metadataで実測する。

4.3 現行実装：5秒の分析操作1回あたり

計算式:

```
入力料金 = 入力tokens ÷ 1,000,000 × 入力単価
```

```
出力料金 = 200 ÷ 1,000,000 × $2.50 = $0.0005
```

モード 入力tokens（5秒） 入力料金 出力料金（仮定） 合計 / 操作

音声のみ 160 $0.00016 $0.00050 **$0.00066**

音声＋映像（低解像度） 500 $0.00015 $0.00050 **$0.00065**

音声＋映像（高解像度） 1,500 $0.00045 $0.00050 **$0.00095**

4.4 現行実装：10回・50回・100回

モード 10回 50回 100回

音声のみ $0.0066 $0.0330 $0.0660 音声＋映像（低解像度） $0.0065 $0.0325 $0.0650 音声＋映像（高解像度） $0.0095 $0.0475 $0.0950

この表はGeminiの入力・出力トークン料金のみ。API呼び出し回数に対する別の固定料金は含めていない。

4.5 将来の連続監視：15分通話1回あたり

15分間を5秒単位で180回送信する想定。メディア入力の合計時間は900秒。

モード 入力tokens / 入力料金 出力tokens（仮定） 出力料金 合計 / 通話 15分

音声のみ 28,800 $0.0288 36,000 $0.0900 **$0.1188**

音声＋映像（低解像度） 90,000 $0.0270 36,000 $0.0900 **$0.1170**

音声＋映像（高解像度） 270,000 $0.0810 36,000 $0.0900 **$0.1710**

4.6 将来の連続監視：10回・50回・100回

モード 10通話 50通話 100通話

音声のみ $1.188 $5.940 $11.880 音声＋映像（低解像度） $1.170 $5.850 $11.700 音声＋映像（高解像度） $1.710 $8.550 $17.100

この表もGeminiのトークン料金のみ。プロンプト入力、リトライ、追加分析、実際の応答tokens、キャッシュ等は含まない。

5. Cloud Run料金

5.1 現在のデプロイ設定

項目 Backend Frontend

サービス名 `detector-backend` `detector-frontend`

リージョン `asia-northeast1` `asia-northeast1`

最大インスタンス 3 3

メモリ 1 GiB スクリプトで未指定

CPU 未指定（試算では1 未指定 vCPUと仮定）

最小インスタンス 未指定（デフォルト0と仮定） 未指定（デフォルト0と仮定）

タイムアウト 60秒 未指定

課金方式 リクエストベースを想定 リクエストベースを想定

2026-11-08に確認した時点で、対象GCPプロジェクトのCloud Runサービス一覧は0件だった。したがって、本章は今後デプロイした場合の想定値であり、実測請求ではない。

5.2 リクエストベース課金の単価と前提

Cloud Run公式料金表のリクエストベース課金の単価を用いる。

項目 単価

CPU（リクエスト処理中） $0.000024 / vCPU-second メモリ（リクエスト処理中） $0.0000025 / GiB-second リクエスト $0.40 / 1,000,000 requests

試算前提:

- Backend: 1 vCPU、1 GiB
- 1リクエストの処理時間: 1秒 / 3秒 / 5秒の3ケース
- メディア送信1回につきBackendリクエスト1回
- 1リクエストあたりの処理中CPU・メモリを課金対象とする
- 最小インスタンス0を仮定
- Frontendへのアクセス、ヘルスチェック、再試行、起動時の追加要素、通信料は除外

計算式:

```
Backend compute cost = requests × processing seconds × (1 × CPU rate + 1 × memory rate)
```

```
Request cost = requests ÷ 1,000,000 × $0.40
```

5.3 現行実装：Backendの概算

処理時間 / APIリクエスト	10リクエスト	50リクエスト	100リクエスト
1秒	\$0.00269	\$0.01345	\$0.02690
3秒	\$0.00799	\$0.03995	\$0.07990
5秒	\$0.01329	\$0.06645	\$0.13290

5.4 将来の連続監視：Backendの概算

1通話180リクエスト、10 / 50 / 100通話を想定する。

処理時間 / APIリクエスト	10通話（1,800 req）	50通話（9,000 req）	100通話（18,000 req）
1秒	\$0.04842	\$0.24210	\$0.48420
3秒	\$0.14382	\$0.71910	\$1.43820
5秒	\$0.23922	\$1.19610	\$2.39220

Cloud Run無料枠は、リクエストベース課金の場合、月あたりCPU 180,000 vCPU-seconds、メモリ360,000 GiB-seconds、リクエスト200万回（us-central1基準）である。無料枠は請求先アカウント単位で集計され、他プロジェクトの使用量と共有される。上記の小規模試算は通常この無料枠内に収まる可能性が高いが、実際の請求は同一請求先アカウント全体の利用量で決まる。

FrontendのCloud Run費用は、メモリ・CPU・ページアクセス数が不明のため本表には含めていない。デプロイ後の設定とアクセスログから別途算出する。

6. Speech-to-Text

6.1 現行実装での利用状況

アプリ本体 `backend/app` を検索した結果、Speech-to-Textクライアントや`recognize()` / `transcribe()`等の呼び出しは確認できなかった。API有効化やIAMロール設定が存在しても、実際のAPIリクエストがなければ音声認識の従量料金は発生しない。

したがって、**現行実装の基本試算ではSpeech-to-Text費用を$0として扱う（未使用のため）。**

6.2 将来導入時の参考単価

Speech-to-Text V1の標準モデル（データロギングなし）は、月60分まで無料、60分を超える部分は$0.024 / 分として料金表に記載されている。リアルタイム認識で採用するAPIバージョン・認識方式・モデルが確定した時点で再確認する。

同一請求先アカウントで同じ月に15分通話を10 / 50 / 100回実施し、全音声をSTT V1標準・データロギングなしで処理すると仮定:

通話数	合計音声時間	無料60分を差し引いた課金時間	概算
10	150分	90分	\$2.16
50	750分	690分	\$16.56
100	1,500分	1,440分	\$34.56

この表は将来の参考値であり、現在のアプリの合計費用には含めない。V2の動的一括認識は別の料金体系であり、リアルタイムストリーミング用途と同一視しない。

7. Firestore

現行アプリ本体にFirestoreの読み書き処理は確認できなかった。API有効化・データベース作成手順・IAMロールの存在だけでは、ドキュメント読み書き料金は発生しない。

そのため現行の基本試算ではFirestore費用を$0として扱う（未使用のため）。

将来利用する場合のStandardエディション無料枠:

- 保存データ: 1 GiB
- ドキュメント読み取り: 50,000 / 日
- ドキュメント書き込み: 20,000 / 日
- ドキュメント削除: 20,000 / 日
- 送信データ転送: 10 GiB / 月

無料枠はプロジェクトごとに1つのデータベースに適用され、日次枠は太平洋時間の午前0時頃にリセットされる。TTL削除、PITR、バックアップ、復元等は無料枠に含まれない。

8. 合計費用の見方

8.1 現行実装

現行機能のGemini費用は非常に小さい。Backend Cloud Run費用も、上記のリクエスト数・処理時間の仮定では少額であり、無料枠の残量に左右される。

現行機能で費用の中心になり得るのは、Gemini以外の未計上サービス、ネットワーク転送、ビルド・イメージ保管、ログ、Frontend稼働などである。これらは実際の利用量を確認して追加する。

8.2 将来の連続監視

将来の連続監視では、15分通話1回につき180回のGeminiリクエストが発生する。現時点の仮定では、Gemini出力を200 tokens / requestと置いているため、出力料金が入力料金と同程度またはそれ以上になるケースがある。

特に高解像度動画では、映像入力tokensが増加する。実装時にはフレームレート・解像度・送信間隔を設計し、実測usage metadataを使って見積もりを更新する。

9. 無料枠・クレジットの扱い

- Gemini Developer API: 料金表に無料枠が掲載されている。無料枠のデータ利用条件を確認し、医療・個人情報を含む可能性のあるデータでの利用可否をチームで判断する。
- Cloud Run: リクエストベース課金の無料枠はCPU・メモリ・リクエスト数に月次上限がある。請求先アカウント内で他プロジェクトと共有される。
- Speech-to-Text V1: 標準モデルでは月60分無料の料金帯がある。対象方式・モデル・請求先アカウントの条件を確認する。
- Firestore: Standardエディションには保存・読み書き等の無料枠がある。プロジェクトごとに1データベースのみ。
- Google Cloud新規顧客向け無料クレジット: 最大$300の案内があるが、アカウント資格・期限・対象サービスの条件があるため、利用可能額として確定計上しない。

無料枠やクレジットは恒久的な単価引き下げではない。利用開始時にコンソール上の適用条件を確認する。

10. コスト削減案

1. **映像フレームレートを制御する:** 動画トークン数はサンプリングFPSに比例するため、必要な場面に絞ってフレームを送る。
2. **解像度を抑える:** 低解像度の動画入力は高解像度よりトークン数を抑えられる。
3. **送信間隔を調整する:** 5秒固定ではなく、リスク兆候やイベントに応じて送信頻度を変える。ただし検知性能・見逃し率を検証する。
4. **音声・映像を必要なときだけ送る:** 常時両方を送るのではなく、分析目的に応じてメディアを選択する。
5. **プロンプトを短くする:** 固定プロンプト・contextのトークン数を計測し、重複情報を減らす。
6. **出力を必要最小限にする:** JSONスキーマと出力上限を設定し、不要な長文応答を避ける。
7. **実測値で見積もりを更新する:** usage metadataを集計し、音声・映像・プロンプト・出力別の平均と最大値を確認する。
8. **Cloud Runの最小インスタンスを増やさない:** コールドスタート要件と費用を比較し、必要性がなければ最小インスタンス0を維持する。
9. **予算アラートを設定する:** Issue #2の予算アラートに本試算を反映し、実請求・予測請求を監視する。

11. 未確定事項・次の確認

未確定事項 影響 確認方法

Gemini Developer API / Vertex 料金体系・認証・データ条件 ADRとデプロイスクリプトをチームで統一 AIの最終採用

Geminiモデルの最終採用 単価・性能 `gemini-2.5-flash`と`gemini-3.5-flash`の不一致を解消

実際の音声・動画MIMEタイプ モデル入力解釈 ブラウザで`blob.type`を確認

動画解像度・フレームサンプリング 動画tokens Gemini usage metadataで測定

1リクエストあたりの応答tokens 出力料金 レスポンスusage metadataを記録

プロンプト・context tokens 入力料金 入力tokensを測定

Cloud Runの実CPU・Frontendメモリ Cloud Run料金 デプロイ後`gcloud run services describe`で確認

Backend平均・P95処理時間 Cloud Run料金・UX Cloud Monitoring / ログで測定

STT導入の有無と方式 STT費用 V1/V2、ストリーミング/バッチを決定

Firestoreのデータ設計 Firestore費用 読み書き頻度・保存期間を設計

通話回数の月内分布 無料枠適用 月次利用計画を作成

12. 参照URL（公式）

料金・仕様の確認日: 2026-11-08

- Gemini Developer API pricing: https://ai.google.dev/gemini-api/docs/pricing?hl=ja
- Gemini token counting: https://ai.google.dev/gemini-api/docs/tokens?hl=ja
- Gemini audio understanding: https://ai.google.dev/gemini-api/docs/audio?hl=ja
- Cloud Run pricing: https://cloud.google.com/run/pricing?hl=ja
- Speech-to-Text pricing: https://cloud.google.com/speech-to-text/pricing?hl=ja
- Firestore pricing: https://cloud.google.com/firestore/pricing?hl=ja
- Firestore quotas and limits: https://cloud.google.com/firestore/quotas?hl=ja
- Google Cloud free trial: https://cloud.google.com/free

13. 計算上の注意

- すべてUSD表記。JPY換算、税、為替手数料は含めない。
- 料金は変更される可能性があるため、デプロイ・発注前に公式料金表を再確認する。
- Geminiのトークン数は公式資料にある標準的な概算であり、実装から取得した実測値ではない。
- 動画の100 / 300 tokens毎秒は、音声を含む動画全体の概算として扱い、音声tokensを重複加算しない。
- 出力200 tokens / requestは比較用の仮定。実際の出力上限・応答tokensを計測して置き換える。
- Cloud Run料金はBackendの概算であり、Frontend、通信、ログ、Artifact Registry、Cloud Build等を含まない。
- Cloud Run無料枠は請求先アカウント内で共有されるため、本プロジェクト単独で無料枠を使い切れるとは限らない。

- Speech-to-TextとFirestoreは現行コードで未使用のため、基本合計には加算しない。